

WOW Digital Humanities Toolkit

Guida all'utilizzo

Panoramica

Il Digital Humanities Toolkit di WOW è uno strumento per l'analisi automatica di testi in formato PDF, pensato per ricercatori e operatori nell'ambito delle Digital Humanities. Il programma elabora il documento caricato, ne estrae il testo tramite OCR e produce un report in formato HTML comprendente grafici, liste di entità riconosciute e analisi del lessico.

Il file di output viene salvato automaticamente nella stessa cartella del PDF di partenza, con lo stesso nome e l'estensione *.html*. È sufficiente aprirlo in un qualsiasi browser per consultarne i risultati.

Requisiti

Il programma è compatibile con Microsoft Windows

Interfaccia e utilizzo

La finestra principale raccoglie tutte le opzioni necessarie all'elaborazione. Di seguito una descrizione di ciascun campo.

- PDF

Percorso del documento da analizzare. Cliccando su *Browse* è possibile selezionare il file desiderato tramite Esplora file. Una volta selezionato, il nome del documento apparirà nel campo di testo e verrà utilizzato come titolo del report HTML generato.

- Pages – Intervallo di pagine

I campi *Start* e *End* consentono di definire l'intervallo di pagine da elaborare.

- Il valore predefinito di *Start* è 1 (prima pagina del documento).
- *End* può essere lasciato vuoto per elaborare il documento fino all'ultima pagina disponibile.
- Sono accettati anche valori negativi: ad esempio, -1 indica l'ultima pagina, -2 la penultima, e così via.

- Options

Names merging

Attiva o disattiva l'accorpamento automatico dei nomi di persona. Quando abilitata, le occorrenze dei cognomi isolati vengono sommate a quelle del nome completo che li contiene, a condizione che quest'ultimo compaia almeno due volte nel testo o sia presente nel Knowledge Graph di WOW.

Esempio: "Dario Fo": 1 + "Fo": 1 diventa "Dario Fo": 2. La funzione supporta cognomi composti da una o due parole (es. "De Niro").

I nomi accorpati vengono evidenziati in grassetto nella lista Persone del report.

NER correction

Attiva o disattiva la correzione automatica dei conflitti nel riconoscimento delle entità. Quando abilitata, se lo stesso termine viene riconosciuto alternativamente come persona o come luogo, il programma lo assegna alla categoria in cui compare più frequentemente.

- Margins – Ritaglio dei margini

Permette di escludere dall'OCR le aree periferiche della pagina, utile per eliminare elementi ricorrenti come numeri di pagina, testate o note a piè pagina. I valori sono espressi come proporzione della dimensione della pagina (da **0** a **1**). Se si inserisce un valore fuori da questo intervallo, il parametro viene automaticamente ripristinato al valore predefinito.

Parametro	Valore predefinito	Descrizione
Header	0.10	Margine superiore (10% dell'altezza)
Footer	0.10	Margine inferiore (10% dell'altezza)
Left	0.05	Margine sinistro (5% della larghezza)
Right	0.05	Margine destro (5% della larghezza)

Avvio dell'elaborazione

Dopo aver selezionato il file e configurato i parametri desiderati, premere il tasto *Process* e attendere il completamento. Al termine, il tasto *Open HTML* si attiverà automaticamente: cliccandolo, il report verrà aperto direttamente nel browser predefinito del sistema.

Struttura del report HTML

Il file HTML generato è un report autonomo che non richiede connessione a internet per essere consultato. È organizzato nelle seguenti sezioni.

Statistiche – Grafici

- **Grafico a torta – Persone:** mostra le persone più citate (fino a 8), con una ulteriore categoria *W* per le persone presenti nel Knowledge Graph di WOW e una categoria *Altri* per le occorrenze rimanenti.
- **Istogramma – Date:** mostra la distribuzione degli anni rilevati nel testo.
- **Istogramma – Luoghi:** mostra gli 8 luoghi per numero di occorrenze.

Parole chiave e collocazioni

Per ciascuna parola chiave del progetto WOW presente tra i 51 sostantivi più frequenti, viene generato un grafo delle collocazioni: le parole che compaiono più spesso in prossimità (entro una finestra di 3 lemmi a sinistra e a destra). Sono inclusi sostantivi, verbi e aggettivi con almeno due occorrenze.

Testo annotato

Il testo completo estratto dal PDF, con evidenziazione a colori delle entità riconosciute.

PERSONE	Nomi di persona rilevati nel testo
LUOGHI	Toponimi e riferimenti geografici
ORGANIZZAZIONI	Enti, istituzioni, aziende
DATE	Anni rilevati tramite espressioni regolari (1800–2050)

Elenco delle entità e dei lemmi

In fondo al report sono presenti le liste complete delle entità riconosciute (persone, luoghi, organizzazioni, date) e dei 51 sostantivi più frequenti nel testo. Per ciascuna voce è indicato il numero di occorrenze. I termini che corrispondono a parole chiave del progetto WOW sono contrassegnati dal simbolo *w* in apice.

Componenti principali

Di seguito le librerie e i moduli che costituiscono la pipeline di elaborazione del tool.

Libreria	Funzione
Tkinter	Costruisce e gestisce l'interfaccia grafica del programma.
PyMuPDF	Rasterizza il documento PDF pagina per pagina, producendo un'immagine PNG a risoluzione doppia (zoom ×2) per ottimizzare la qualità dell'OCR.
PIL / PILLOW	Ritaglia i margini dell'immagine in base ai parametri impostati, rimuovendo elementi indesiderati come numeri di pagina.

Pytesseract / Tesseract	Esegue il riconoscimento ottico dei caratteri (OCR) sul testo in italiano, gestendo correttamente layout complessi come il testo su più colonne.
Stanza NLP	Esegue la tokenizzazione, l'espansione dei token composti (MWT expansion), il POS tagging, la lemmatizzazione e il riconoscimento delle entità nel testo (NER).
Matplotlib	Genera i grafici a torta, gli istogrammi e i grafici a barre inclusi nel report HTML.
NetworkX	Costruisce e visualizza i grafi delle collocazioni per le parole chiave del progetto.

Riferimenti

- **Tkinter:** <https://docs.python.org/3/library/tkinter.html>
- **PyMuPDF:** <https://pymupdf.readthedocs.io/>
- **Pillow:** <https://pillow.readthedocs.io/>
- **Pytesseract:** <https://github.com/madmaze/pytesseract>
- **Tesseract OCR:** <https://github.com/tesseract-ocr/tesseract>
- **Stanza NLP:** <https://stanfordnlp.github.io/stanza/>
- **Matplotlib:** <https://matplotlib.org/stable/>
- **NetworkX:** <https://networkx.org/documentation/stable/>